

Pourquoi $\kappa = 1.0$ est structurellement inatteignable pour CSTL

Et pourquoi le désaccord détecté est résolu, pas subi — 31 août 2026

1. Le résultat qui a mené à cette analyse

Un test de fidélité sémantique (3 juges LLM indépendants : GPT, DeepSeek, Gemini) a été mené sur deux corpus distincts, avec la même échelle de mesure continue [0.0–1.0] :

Type de contenu	N	Écart-type inter-juges	Interprétation
Factuel / logique (contrôle)	3 items × 3 juges	0.048	Convergence quasi-totale
Jugement de valeur (interprétatif)	6 items × 3 juges	0.098	Divergence ~2× plus élevée

2. L'erreur de mesure : appliquer κ à un corpus mixte

κ (Fleiss, Cohen) mesure l'accord entre juges **au-delà du hasard**. Il présuppose implicitement qu'il existe une **bonne réponse unique** pour chaque item, et que tout désaccord constitue une erreur de mesure à éliminer.

Cette présupposition est valide pour du contenu factuel : « la dose est-elle 4 mg ? » a une réponse déterminée. Elle est **invalid**e pour du contenu interprétatif : « ce payload donne-t-il assez d'information à un clinicien pour juger la sécurité globale ? » est une question où des experts compétents divergent légitimement.

Appliquer un κ global à un corpus contenant les deux types produit donc un nombre qui **pénalise le système pour un comportement correct**. Le plafond n'est pas fixé par la qualité de CSTL, mais par la proportion de contenu interprétatif dans le corpus testé.

3. Le désaccord n'est pas subi : il est détecté, routé, puis tranché

Le point essentiel — souvent mal compris — est que le désaccord détecté n'est **pas** une impasse laissée en suspens. Il déclenche une chaîne de résolution complète, dont le maillon final est un arbitrage humain :

Étape	Mécanisme	Sortie
1. Détection	Divergence inter-juges au-delà du seuil de convergence	Item marqué pour quarantaine
2. Quarantaine	Item isolé du flux automatique, σ maintenu bas (honnêteté épistémique préservée)	Item non propagé comme fait établi en aval
3. Arbitrage	Conseil humain (RestrictedCouncil, quorum 2/3)	Décision tranchée, tracée, attribuée
4. Réinjection	Verdict humain encodé avec provenance complète (qui, quand, sur quelle base)	σ mis à jour, chaîne d'audit complète du doute à la décision

Autrement dit : κ mesure l'étape 1 et la traite comme un échec ; l'architecture traite l'étape 1 comme un succès de détection, et confie la résolution à l'étape 3. Le système ne prétend pas que la machine tranche les jugements de valeur — il garantit qu'elle *reconnaît* qu'elle ne doit pas les trancher seule.

4. Ce que cela change pour le critère de succès

	Ce que κ global mesure	Ce que l'architecture promet
Question posée	Les juges sont-ils d'accord sans aide ?	Le désaccord est-il détecté, routé et tranché ?
Désaccord sur un jugement de valeur	Pénalité (fait chuter κ)	Succès (quarantaine + arbitrage humain déclenchés)
Cible réaliste	$\kappa \rightarrow 1.0$ (impossible)	Recall de détection $\rightarrow 100\%$, volume d'escalade soutenable

5. Le paradoxe de prévalence : une seconde raison, purement statistique

Un effet indépendant, observé trois fois durant la session, aggrave le problème. Quand la quasi-totalité des jugements convergent vers « préservé » (prévalence $> 90\%$), l'accord attendu par hasard (P_e) devient lui-même très élevé. Le dénominateur ($1 - P_e$) se réduit fortement, et un seul désaccord fait chuter κ de façon disproportionnée.

Illustration mesurée : sur 20 items du benchmark FraCaS, **19 accords unanimes sur 20** (95 % d'accord brut) ont produit un κ de **-0.017**. Le κ seul est donc trompeur à haute prévalence — phénomène documenté (Cicchetti & Feinstein, 1990).

6. Formulation recommandée pour publication

À éviter : « CSTL atteint $\kappa = X$ sur la fidélité sémantique. » Un κ global agrège deux régimes incommensurables et masque le comportement réel du système.

À privilégier — trois métriques séparées :

(a) κ sur le sous-ensemble factuel — cible élevée, mesure la fiabilité du transport sémantique. Seule métrique où κ est épistémiquement valide.

(b) Variance sur le sous-ensemble interprétatif — attendue non nulle. Une variance faible ici signifierait un *faux consensus*, c'est-à-dire un défaut, pas une qualité.

(c) Recall de détection + taux de résolution par le conseil — proportion des cas ambigus effectivement mis en quarantaine, et proportion de ceux-ci effectivement tranchés par arbitrage humain. C'est la métrique qui correspond réellement à la promesse architecturale de bout en bout.

7. Conclusion

$\kappa = 1.0$ n'est pas un objectif que CSTL n'a pas encore atteint : c'est un objectif **incompatible avec sa conception**. Un système qui atteindrait $\kappa = 1.0$ sur un corpus contenant des jugements de valeur aurait nécessairement forcé un consensus artificiel sur des questions légitimement contestables — supprimant précisément l'information que la quarantaine existe pour préserver, et court-circuitant l'arbitrage humain qui doit trancher.

La divergence sur le contenu interprétatif n'est pas du bruit à réduire. C'est le signal qui déclenche l'arbitrage humain — et ce signal, une fois transmis au conseil, aboutit à une décision tracée. Le désaccord est résolu, pas ignoré ; simplement, il est résolu par l'humain, à l'endroit prévu pour cela.

Note méthodologique — les échantillons de cette session sont petits ($n = 3$ à 24 selon le test) et les résultats sont directionnels, non définitifs. L'argument structurel est indépendant de la taille d'échantillon ; les chiffres cités l'illustrent sans le démontrer à eux seuls. Une réplication à plus grande échelle ($n \geq 100$ par régime) reste nécessaire avant toute affirmation quantitative ferme. Le taux de résolution par le conseil humain n'a pas encore été mesuré en conditions de production.